

PHÂN TÍCH VÀ DỰ ĐOÁN DIỄN BIẾN ĐỘT QUỴ DỰA TRÊN KHUNG ISIR

MÔN HỌC: KHAI PHÁ DỮ LIỆU

GVHD : ĐỖ NHƯ TÀI

Sinh viên: Mai Thị Thúy An

Trần Đoàn Phương Quyên


Nguyễn Thị Phương Thanh



1.MỞ ĐẦU

LÝ DO CHỌN ĐỀ TÀI

- Đột quỵ là bệnh lý nguy hiểm, gây tử vong và tàn phế cao
- Nhiều yếu tố nguy cơ cùng tác động: tuổi, huyết áp, tim mạch, đường huyết, BMI
- Mối quan hệ giữa các yếu tố phức tạp, khó đánh giá thủ công
- Khai phá dữ liệu & học máy giúp phân tích đa biến và dự đoán sớm nguy cơ
- Khung ISIR hỗ trợ phân tích có hệ thống và logic



1.MỞ ĐẦU

MỤC TIÊU NGHIÊN CỨU

- Phân tích và khám phá dữ liệu bệnh nhân đột quy thông qua phân tích dữ liệu khám phá (EDA)
- Xác định các yếu tố nguy cơ chính ảnh hưởng đến khả năng xảy ra đột quy
- Áp dụng khung ISIR để tổ chức quá trình phân tích dữ liệu một cách hệ thống
- Thực hiện phân nhóm bệnh nhân dựa trên các đặc trưng nguy cơ
- Xây dựng và đánh giá các mô hình học máy nhằm dự đoán nguy cơ đột quy
- Mục tiêu hỗ trợ chẩn đoán sớm, giảm tải y tế

1. MỞ ĐẦU

CÁC CÂU HỎI NGHIÊN CỨU

Mô hình học máy nào cho hiệu quả tốt nhất trong việc phát hiện sớm nguy cơ đột quỵ, với trọng tâm là tối ưu Recall cho lớp bệnh nhân đột quỵ.

Việc áp dụng các kỹ thuật xử lý dữ liệu mất cân bằng (class_weight, SMOTE) có cải thiện đáng kể khả năng phát hiện bệnh nhân đột quỵ (Recall, AUC-ROC) của các mô hình hay không?

Trong bối cảnh dữ liệu mất cân bằng, chỉ số đánh giá nào (Recall, F1-score, AUC-ROC) là phù hợp nhất để đánh giá mô hình dự đoán đột quỵ?

Các kỹ thuật phân cụm (K-Means, DBSCAN) có thể phát hiện các nhóm bệnh nhân với mức độ nguy cơ đột quỵ khác nhau hay không?

2.DỮ LIỆU & PHƯƠNG PHÁP

DỮ LIỆU NGHIÊN CỨU


- Nguồn dữ liệu: Kaggle – Stroke Prediction (kaggle.com/datasets/fedesoriano/stroke-prediction-dataset)
- Số lượng mẫu: 5.110 bệnh nhân
- Số biến: 12 biến, bao gồm: tuổi, giới tính, BMI, huyết áp, đường huyết, bệnh tim, ...
- Biến mục tiêu: Stroke (0 = không, 1 = có đột quỵ)
- Mục đích sử dụng dữ liệu: Phân tích yếu tố nguy cơ, phân nhóm và dự đoán nguy cơ đột quỵ

```
RangeIndex: 5110 entries, 0 to 5109
Data columns (total 12 columns):
 #   Column              Non-Null Count  Dtype  
---  -
 0   id                  5110 non-null   int64  
 1   gender              5110 non-null   object  
 2   age                 5110 non-null   float64 
 3   hypertension        5110 non-null   int64  
 4   heart_disease       5110 non-null   int64  
 5   ever_married        5110 non-null   object  
 6   work_type           5110 non-null   object  
 7   Residence_type      5110 non-null   object  
 8   avg_glucose_level   5110 non-null   float64 
 9   bmi                 4909 non-null   float64 
10   smoking_status      5110 non-null   object  
11   stroke              5110 non-null   int64  
dtypes: float64(3), int64(4), object(5)
memory usage: 479.2+ KB
      missing      pct
bmi      201  3.933464
```

2. DỮ LIỆU & PHƯƠNG PHÁP

TIỀN XỬ LÝ DỮ LIỆU


- Xử lý dữ liệu thiếu: Biến BMI có giá trị thiếu → điền bằng trung vị / median
- Mã hóa biến phân loại: Gender, Smoking, Heart Disease → One-hot encoding hoặc Label encoding
- Chuẩn hóa dữ liệu: Các biến số như Age, BMI, Glucose → MinMax hoặc StandardScaler
- Xử lý mất cân bằng lớp (Imbalanced Data):
- Sử dụng `class_weight` hoặc SMOTE
- Nhằm tối ưu Recall cho lớp bệnh nhân đột quỵ



2.DỮ LIỆU & PHƯƠNG PHÁP

KHUNG ISIR


- Insight: Khám phá dữ liệu, hiểu đặc điểm các biến và mối quan hệ giữa các yếu tố nguy cơ
- Segmentation: Phân nhóm bệnh nhân theo mức độ nguy cơ đột quỵ
- Intervention: Đánh giá tác động của các yếu tố nguy cơ đến khả năng xảy ra đột quỵ
- Response: Xây dựng và đánh giá các mô hình học máy dự đoán nguy cơ đột quỵ



2. DỮ LIỆU & PHƯƠNG PHÁP

THUẬT TOÁN SỬ DỤNG

- Logistic Regression
- Decision Tree
- Random Forest
- SVM (Support Vector Machine)
- Gradient Boosting / XGBoost




2.DỮ LIỆU & PHƯƠNG PHÁP

CHỈ SỐ ĐÁNH GIÁ

- Accuracy – tổng thể
- Precision – dự đoán đúng lớp Stroke
- Recall – nhấn mạnh: phát hiện bệnh nhân đột quỵ
- F1-score – cân bằng Precision & Recall
- AUC-ROC – khả năng phân biệt lớp

3.KẾT QUẢ THEO ISIR

INSIGHT: Khám phá dữ liệu




- Tuổi, huyết áp, đường huyết có liên quan mạnh đến Stroke
- BMI ít ảnh hưởng hơn
- Dữ liệu ban đầu mất cân bằng: lớp Stroke < 5%


3.KẾT QUẢ THEO ISIR

INSIGHT: Nhận xét


- Tuổi là yếu tố nguy cơ quan trọng nhất



- Biến BMI và hút thuốc ảnh hưởng thấp





- Hypertension & Glucose có ảnh hưởng đáng kể



3.KẾT QUẢ THEO ISIR

SEGMENTATION: Phân nhóm



- Nhóm nguy cơ thấp: trẻ, không tăng HA
- Nhóm trung bình
- Nhóm nguy cơ cao: tuổi cao, tăng HA, glucose cao


3.KẾT QUẢ THEO ISIR

INTERVENTION: Hàm ý lâm sàng

- Kiểm soát huyết áp và đường huyết là quan trọng
- Can thiệp sớm nhóm nguy cơ cao
- Phân nhóm giúp cá nhân hóa dự đoán

3.KẾT QUẢ THEO ISIR

RESPONSE: So sánh mô hình



- Logistic Regression: Recall cao và ổn định
- Random Forest: Ưu tiên Precision hơn Recall
- SVM: Hiệu quả ở mức trung bình
- Gradient Boosting / XGBoost: Kết quả so sánh được, không vượt trội rõ rệt

3.KẾT QUẢ THEO ISIR

MÔ HÌNH TỐT NHẤT

- Logistic Regression được lựa chọn
- Recall cao cho lớp bệnh nhân đột quỵ
- AUC-ROC tốt, khả năng phân biệt lớp ổn định
- Accuracy ≈ 0.76 (chỉ mang tính tham khảo)



4.KẾT LUẬN – HẠN CHẾ

KẾT LUẬN

- ML hỗ trợ dự đoán đột quỵ hiệu quả
- Tuổi & huyết áp là yếu tố quan trọng nhất
- Logistic Regression phù hợp dữ liệu và mục tiêu y tế

4.KẾT LUẬN – HẠN CHẾ


HẠN CHẾ

- Dữ liệu đơn nguồn (Kaggle)
- Không có dữ liệu hình ảnh (CT/MRI)
- Lớp Stroke vẫn ít → mất cân bằng còn tồn tại

4.KẾT LUẬN – HẠN CHẾ HƯỚNG PHÁT TRIỂN

- Kết hợp CT/MRI / dữ liệu hình ảnh
- Áp dụng deep learning để nâng cao dự đoán
- Thu thập dữ liệu đa trung tâm để tăng độ chính xác

DẤU HIỆU NHẬN BIẾT SỚM BỆNH



NỖ LỰC KIỂM SOÁT BỆNH

TRẢ LỜI CÂU HỎI NGHIÊM CỨU

Câu 1: Mô hình hiệu quả nhất để phát hiện sớm nguy cơ đột quỵ

✓ Logistic Regression: Recall cao và ổn định

Câu 2: Xử lý dữ liệu mất cân bằng (class_weight, SMOTE) có cải thiện không?

✓ Có, tăng Recall và AUC-ROC cho các mô hình

Câu 3: Chỉ số đánh giá phù hợp nhất trong dữ liệu mất cân bằng

✓ Recall ưu tiên, F1-score & AUC-ROC hỗ trợ

Câu 4: Phân cụm có phát hiện nhóm nguy cơ khác nhau không?

✓ K-Means / DBSCAN xác định nhóm nguy cơ cao, trung bình, thấp



Thank You.
Teacher!